

ETL: Inversión en I+D LATAM

Script automatizado para cargar datos de inversión en I+D a SQL Server en 5 minutos.

Requisitos Previos

1. SQL Server instalado

- SQL Server Express (gratuito) o superior
- SQL Server Management Studio (SSMS) para ejecutar scripts

2. Python 3.8+

```
bash  
  
python --version
```

3. ODBC Driver 17 for SQL Server

Windows: Descargar desde <https://learn.microsoft.com/en-us/sql/connect/odbc/download-odbc-driver-for-sql-server>

Instalación (5 minutos)

Paso 1: Clonar/Descargar archivos

```
bash  
  
# Asegúrate de tener estos 3 archivos en la misma carpeta:  
# - 01_crear_bd_inversion.sql  
# - 02_etl_inversion.py  
# - README.md (este archivo)  
# - inversion.xlsx (tu dataset)
```

Paso 2: Instalar dependencias Python

```
bash  
  
pip install pandas openpyxl sqlalchemy pyodbc
```

Paso 3: Crear la base de datos en SQL Server

Opción A: Desde SQL Server Management Studio (SSMS)

1. Abre SSMS
2. Conecta a tu SQL Server (ej: `localhost` o `NACHO-PC\SQLEXPRESS`)
3. Abre el archivo `01_crear_bd_inversion.sql`

4. Ejecuta (F5 o Ctrl+E)

Opción B: Desde command line

```
bash
```

```
sqlcmd -S localhost -U sa -P tu_password -i 01_crear_bd_inversion.sql
```

Paso 4: Configurar credenciales Python

Abre `02_etl_inversion.py` y busca esta sección:

```
python
```

```
SQL_SERVER_CONFIG = {  
    'server': 'localhost', # ← CAMBIAR AQUÍ (tu servidor)  
    'database': 'InversionID',  
    'username': 'sa', # ← CAMBIAR AQUÍ (tu usuario)  
    'password': 'tu_password', # ← CAMBIAR AQUÍ (tu contraseña)  
    'driver': 'ODBC Driver 17 for SQL Server'  
}
```

Ejemplos de server:

- `localhost` - SQL Server local
- `NACHO-PC\SQLEXPRESS` - SQL Server Express en la máquina
- `192.168.1.100` - SQL Server remoto
- `servidor.database.windows.net` - Azure SQL

Paso 5: Ejecutar el script ETL

```
bash
```

```
python 02_etl_inversion.py
```

Esperado:

```
INFO -  Conexión a SQL Server exitosa  
INFO -  Leyendo archivo: inversion.xlsx  
INFO -  Normalizando: DIM_TIEMPO  
INFO -  Cargando datos en SQL Server...  
INFO -  Todos los datos cargados correctamente  
INFO -  ETL COMPLETADO EXITOSAMENTE
```

✅ Validar que funcionó

Desde SSMS:

sql

```
-- Conecta a la base de datos InversionID y ejecuta:  
USE InversionID;  
  
-- Ver años cargados  
SELECT * FROM dim_tiempo;  
  
-- Ver sectores  
SELECT * FROM dim_sector;  
  
-- Ver inversión total por año  
SELECT * FROM vw_inversion_total_anio;  
  
-- Ver top 10 provincias  
SELECT TOP 10 * FROM vw_top_provincias_anio WHERE ranking <= 5;
```

📊 Estructura de datos

Dimensiones

- **dim_tiempo:** 21 años (2004-2024)
- **dim_sector:** 5 sectores (públicos, privados, ONGs, empresas)
- **dim_provincia:** ~24 provincias argentinas
- **dim_disciplina:** ~7 disciplinas científicas

Tablas de Hechos

- **fact_inversion_general:** Datos agregados nacionales
- **fact_inversion_por_sector:** Inversión desagregada por sector
- **fact_inversion_por_provincia:** Inversión desagregada por provincia
- **fact_inversion_por_disciplina:** Inversión desagregada por disciplina

Vistas Útiles

sql

```
SELECT * FROM vw_inversion_total_anio; -- Inversión anual  
SELECT * FROM vw_top_sectores_anio;    -- Ranking de sectores  
SELECT * FROM vw_top_provincias_anio;  -- Ranking de provincias  
SELECT * FROM vw_disciplina_tendencia; -- Evolución disciplinas
```

Troubleshooting

Error: "Connection refused" o "Named Pipes Provider, error: 40"

Solución: Verifica que:

- SQL Server está corriendo (Services → SQL Server)
- El nombre de servidor es correcto
- Las credenciales son válidas

Error: "ODBC Driver 17 not found"

Solución: Instala el driver desde: <https://learn.microsoft.com/en-us/sql/connect/odbc/download-odbc-driver-for-sql-server>

Error: "Login failed for user 'sa'"

Solución:

- Verifica credenciales en el script
- Si SQL Server está en modo Windows Auth, no uses 'sa'

Error: "Database InversionID already exists"

Solución: Ejecuta en SSMS:

```
sql  
  
DROP DATABASE InversionID;
```

Próximos pasos (después de esto)

1. **EDA en Python:** Usa este notebook template

```
python  
  
import pandas as pd  
import pyodbc  
  
conn = pyodbc.connect(...)   
df = pd.read_sql("SELECT * FROM vw_inversion_total_anio", conn)  
df.plot(x='anio')
```

2. **Conectar a Tableau:**

- Data → New Data Source → SQL Server
- Server: localhost
- Database: InversionID
- Elige la tabla

3. **ML**: Forecasting, clustering con scikit-learn

Notas

- El script es **idempotente**: Si lo ejecutas 2 veces, te dará error en la carga (va a intentar insertar duplicados). Para re-ejecutar, borra la BD y corre el SQL nuevamente.
- Los datos están en **pesos corrientes**, **pesos constantes** y **dólares** según columna
- El dataset es **limpio**: sin valores nulos ni anomalías evidentes

Soporte

Si algo no funciona, revisa:

1. ¿Está corriendo SQL Server?
2. ¿Tenés conexión a la BD? (trata de hacer ping con SSMS)
3. ¿Las credenciales son correctas?
4. ¿El archivo inversion.xlsx está en la ruta correcta?

Contacto

Para preguntas sobre el script, pasá por el grupo de Slack!